UNIVERSIDAD EXTERNADO DE COLOMBIA · DEEP LEARNING · ENTREGA FINAL

¿Se justificaba una red Transformer para pronosticar el PM2,5 de Fontibón?

Réplica, traslado y auditoría de una STN con atención dispersa, de Beijing a Bogotá

Johan Velandia
Docente: Wilmer Darío Pineda Ríos

Bogotá, 2026

LA PREGUNTA Y CÓMO SE IBA A JUZGAR

¿Lo aprendido en Beijing mejora el pronóstico de la próxima hora en Fontibón?

Ventana de 24 horas → PM2,5 en t+1. Comparación contra la misma red entrenada desde cero y contra una regresión Ridge.

CRITERIO 1 · FIJADO EN LA FASE 1

¿Se justifica la profundidad?

Solo si la STN reduce el RMSE de Ridge de forma consistente **y** mejora en los episodios de concentración alta.

CRITERIO 2 · FIJADO EN LA FASE 1

¿Sirve la transferencia?

Solo si la STN preentrenada en Beijing supera de forma consistente a la misma red entrenada desde cero.

EL ARTÍCULO BASE · ZHANG Y ZHANG (2023)

La STN: un encoder–decoder con atención dispersa

Entrada del artículo

24 horas con las 8 variables de Beijing

→

Encoder

Atención dispersa: solo las consultas más informativas calculan atención completa. Conv1D y MaxPool resumen la historia; una rama corta conserva las últimas 12 horas.

→

Decoder

Últimas 12 horas de PM2,5 más una casilla vacía. Máscara causal y atención cruzada con el encoder.

→

Salida

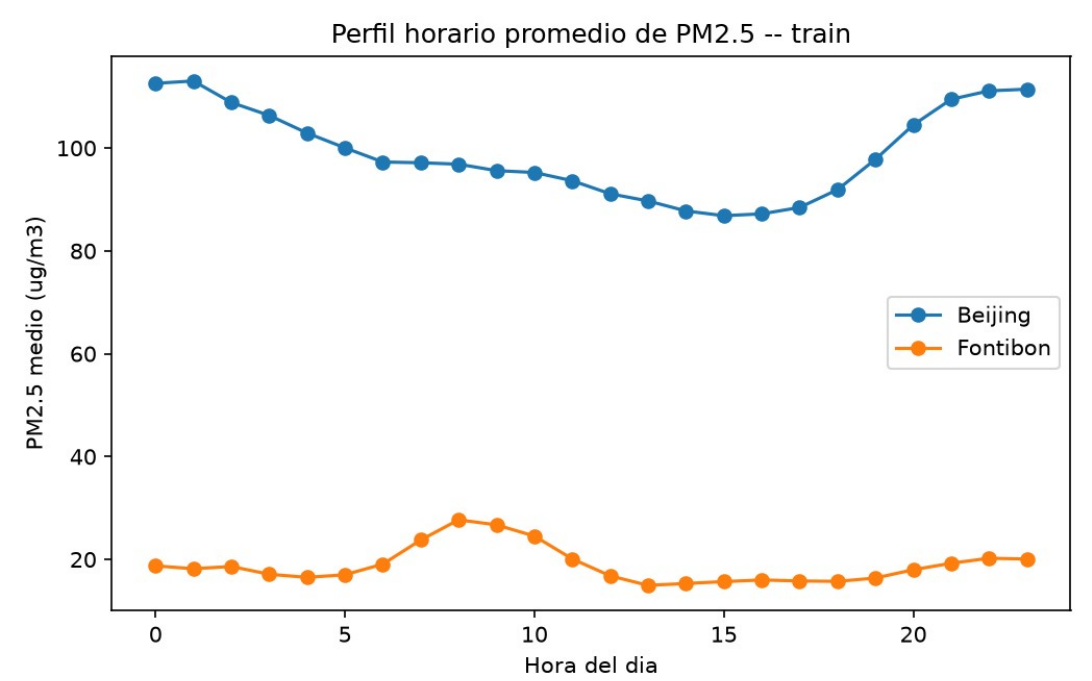
Un número: PM2,5 de la hora siguiente

Del artículo: ventana de 24 h, pérdida MSE, Adam con tasa 10^{-4}, lote 32, escalado MinMax.

Adaptado para transferencia: 24 h × 3 variables compartidas; red reducida (2 encoders y 1 decoder) y validación cronológica.

DOS DOMINIOS MUY DISTINTOS

Beijing y Fontibón no comparten ni nivel ni dinámica



Entrenamiento	Beijing	Fontibón
PM2,5 medio	99,0	18,9
Desviación	91,7	10,8
Autocorrelación 1 h	0,96	0,74
Ventanas train	29.237	10.802

Fontibón: partición cronológica 70/15/15 antes de imputar (10.802 / 2.564 / 2.574 ventanas), escalador propio ajustado solo con entrenamiento.

STN · Beijing → Fontibón · 4 · µg/m³ salvo autocorrelación y ventanas

FASE 1 · LÍNEA BASE

Ridge fue la referencia que la red debía superar

Fontibón, validación	RMSE	R^2
Ridge	6,545	0,587
Random Forest	6,583	0,582
Persistencia	7,570	0,447
Valor de hace 24 h	12,715	−0,560

RMSE como métrica principal: es la del artículo y castiga más los errores grandes, los de los picos.

Ridge se eligió solo con validación. En test: RMSE **7,063**, frente a 8,232 de la persistencia.

Su falla: con PM2,5 ≥ 40 subestima en **15 µg/m³** en promedio.

STN · Beijing → Fontibón · 5 · RMSE en µg/m³, mismas ventanas y particiones para todos

FASE 2 · RÉPLICA EN BEIJING

La réplica reducida quedó cerca del artículo

Beijing, test 2014	RMSE	MAE	R^2
Artículo	19,04	11,13	0,937
Réplica R1 (3 semillas)	21,13 ± 0,40	11,86	0,949
Persistencia	22,02	—	—

RMSE unos **11 % mayor** que el publicado, con una red más pequeña, validación cronológica y otras decisiones de imputación.

Después, **R2**: la misma red preentrenada solo con las 3 variables que comparte con Fontibón (validación RMSE 21,06 ± 0,085).

FASE 2 · TRANSFERENCIA HACIA FONTIBÓN (VALIDACIÓN)

Entrenar desde cero fue mejor que transferir

Estrategia	Qué se entrena	Semillas	RMSE validación
A · desde cero	Toda la red, sin pesos de Beijing	3	6,314 ± 0,061
C · ajuste parcial	Decoder y salida; encoder congelado	3	6,627 ± 0,040
B · congelado	Solo la salida (33 parámetros)	2	6,834 ± 0,016
D · ajuste completo	Toda la red, tasa 10^{-5} en el encoder	—	solo piloto
Ridge (línea base)	Regresión sobre ventanas aplanadas	—	6,545

Ya en validación, B y C quedaron por encima de Ridge y de A. D y la tercera semilla de B no se completaron: son limitaciones declaradas.

STN · Beijing → Fontibón · 7 · RMSE en µg/m³, 2.564 ventanas de validación

FASE 3 · ANTES DE ABRIR EL CONJUNTO DE PRUEBA

El test se evaluó una sola vez, con todo congelado

1

Congelar

Modelo final A, semillas, métricas, umbrales y criterios por escrito, con el SHA-256 de cada checkpoint.

2

Verificar

Los 8 checkpoints reproducen su RMSE de validación (diferencia 0,0) y Ridge su 7,063.

3

Evaluar una vez

Solo inferencia. El script se niega a correr de nuevo si ya existe un resultado.

4

Auditar

Explicabilidad y fallas sobre el modelo ya congelado; nada de eso cambia la selección.

RESULTADO EN TEST · 2.574 VENTANAS, SEP–DIC 2022

A le gana a Ridge en las tres semillas, por poco

−2,7 %

de RMSE frente a Ridge (−0,19 µg/m³). IC 95 % por bloques: excluye el cero en las 3 semillas.

A acierta mejor que Ridge en solo el **51–53 %** de las ventanas.

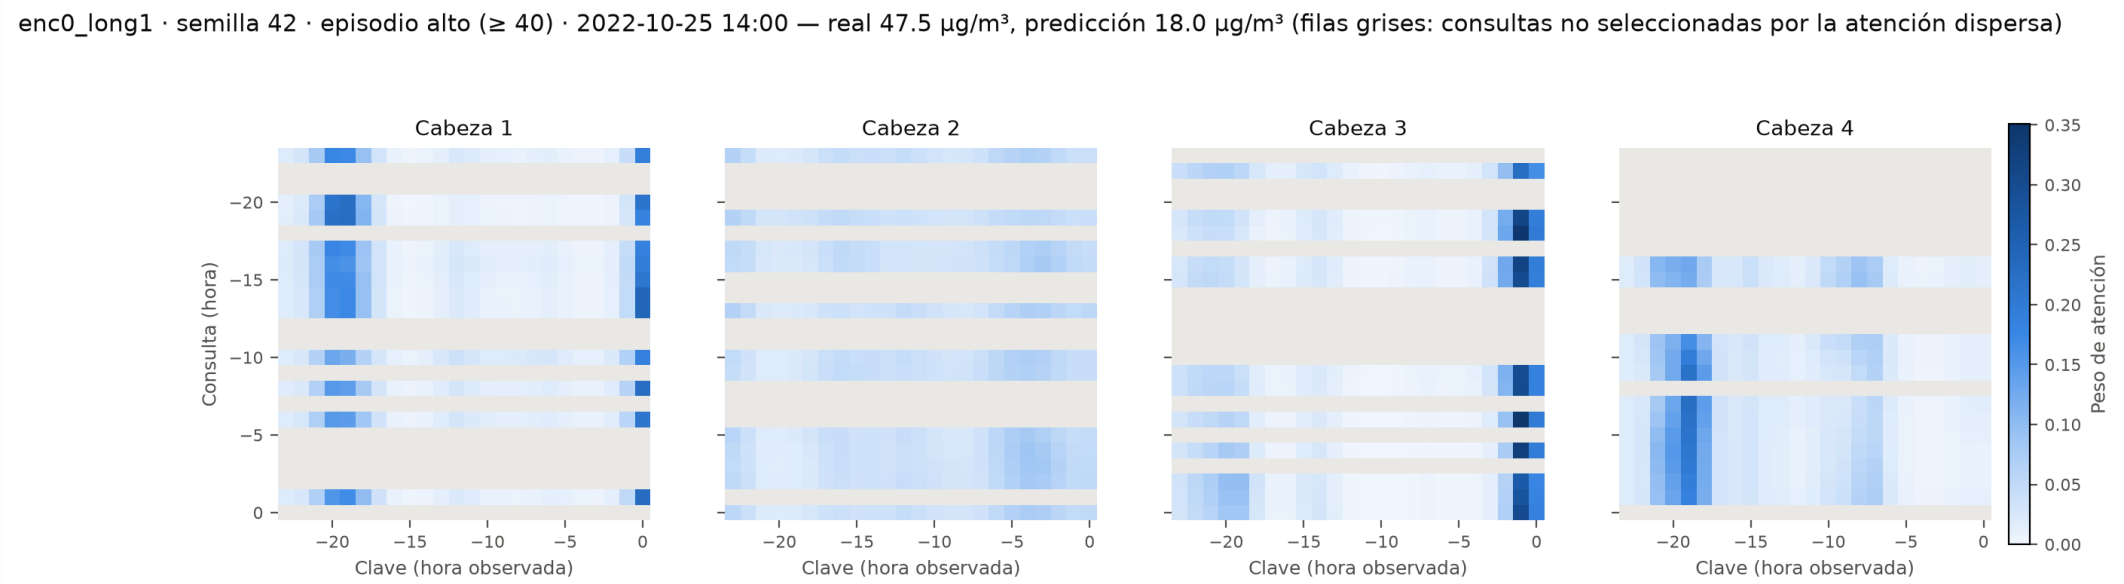
Modelo	RMSE	RMSE ≥ 40	Sesgo ≥ 40
A (3 semillas)	6,869	17,25	−13,95
Ridge	7,063	17,87	−14,96
C (3 semillas)	7,274	18,77	−15,73
B (2 semillas)	7,484	19,52	−16,70
Persistencia	8,232	16,66	−9,80

La transferencia tampoco ayuda en test: B y C quedan peor que A y que Ridge. En los picos, la persistencia es mejor que todos.

STN · Beijing → Fontibón · 9 · µg/m³; “≥ 40” = 118 ventanas con PM2,5 real ≥ 40

AUDITORÍA · MATRICES DE ATENCIÓN CONSULTA × CLAVE

La atención parece estar dominada por la posición



Franjas verticales: cada cabeza mira casi siempre las mismas horas, sea cual sea la consulta.

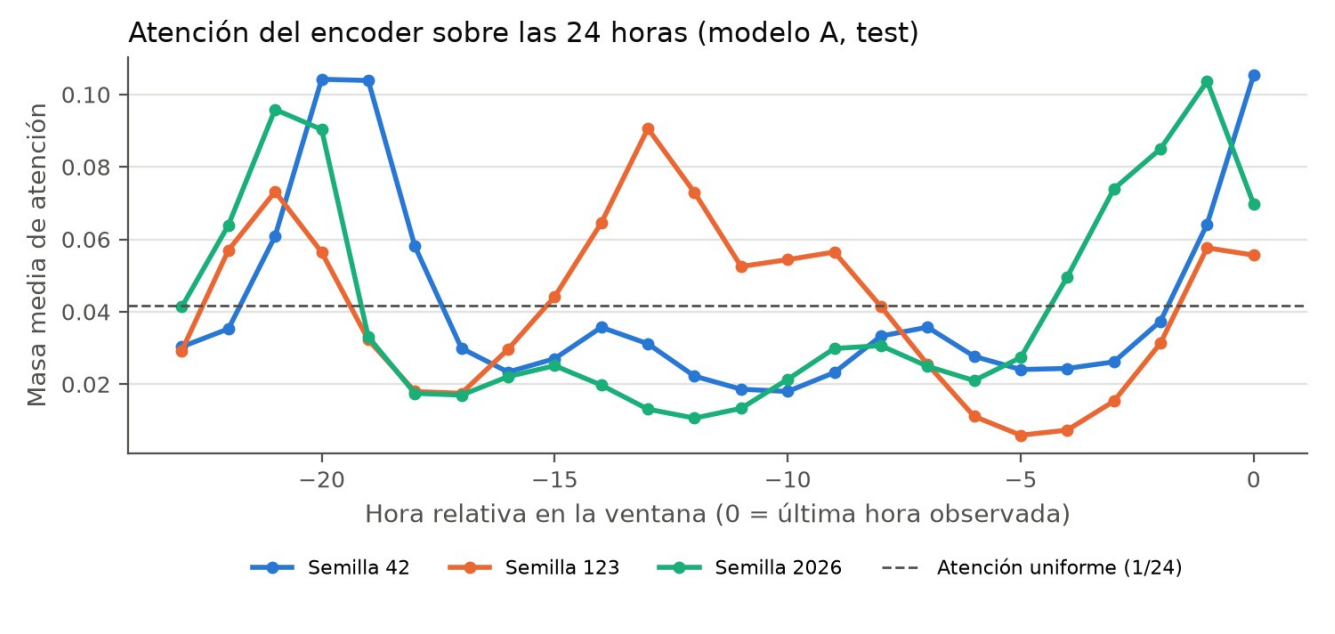
Normal y alto iguales: sin diferencia reproducible entre semillas.

Casos sintéticos: la predicción cambia de 20,7 a 32,7; la atención apenas se mueve.

STN · Beijing → Fontibón · 10 · Pesos reales de la primera capa del encoder, semilla 42, episodio alto del 25-oct 14:00

AUDITORÍA · MAPAS DE ATENCIÓN

La atención no es una explicación estable



Atención en las últimas 6 h: **0,17 · 0,28 · 0,41** según la semilla

Importancia de esas mismas horas: **0,69 · 0,69 · 0,71**

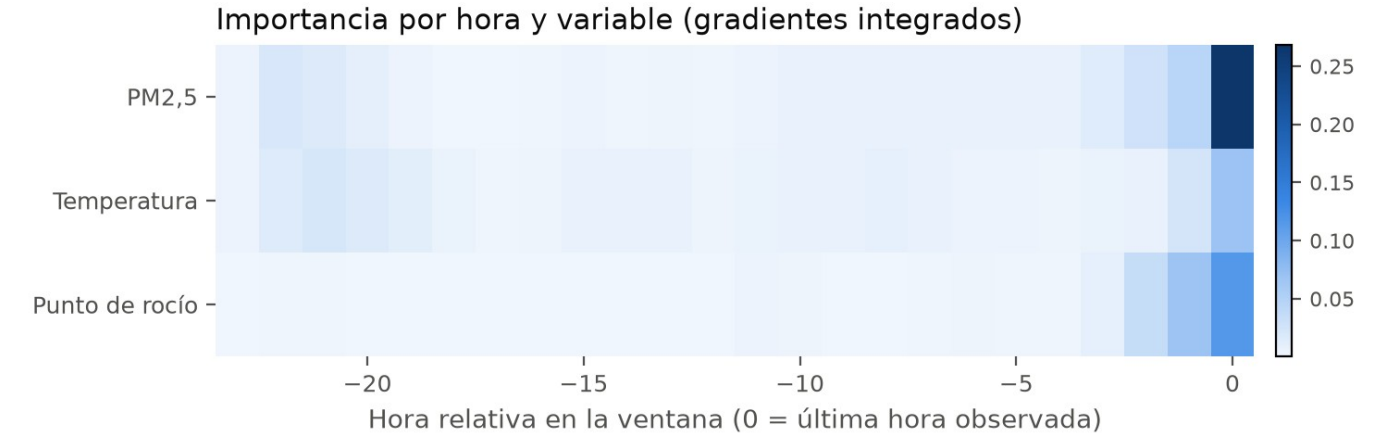
Misma predicción, distintas rutas internas

Por eso la lectura de qué aprendió la red se apoya en atribuciones y ablaciones; los mapas de atención quedan como evidencia complementaria.

STN · Beijing → Fontibón · 11 · Mapas extraídos con un forward manual verificado (diferencia ≤ 2×10^{-7})

AUDITORÍA · GRADIENTES INTEGRADOS

La red usa las horas recientes y la meteorología



70 % de la importancia está en las últimas 6 horas

46 % PM2,5 · **27 %** temperatura · **27 %** punto de rocío

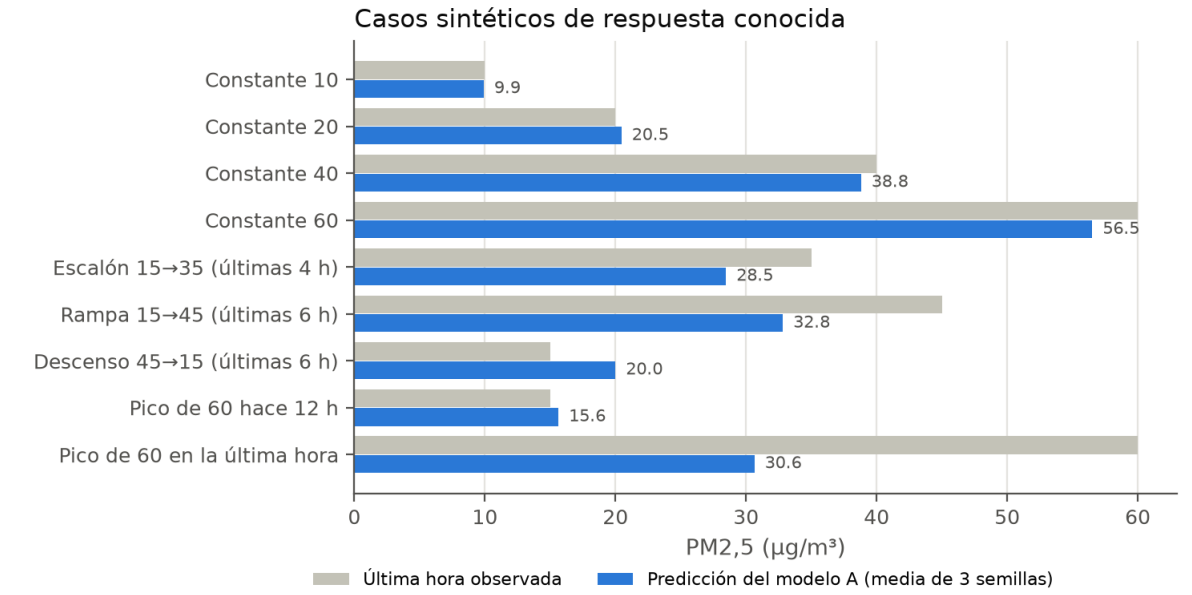
Igual en las 3 semillas (desviación ≤ 0,02)

Verificado: las atribuciones suman el cambio de la predicción (error ≈ 5 %). Si se borra la meteorología, el RMSE sube +0,69; si se desordenan las horas, +4,30.

STN · Beijing → Fontibón · 12 · 518 ventanas de test (118 episodios ≥ 40 y 400 al azar)

AUDITORÍA · ¿SEÑAL O ATAJO?

El modelo aprendió una persistencia suavizada



Se parece más a la **última hora** (correlación 0,90) que al valor real a predecir (0,785)

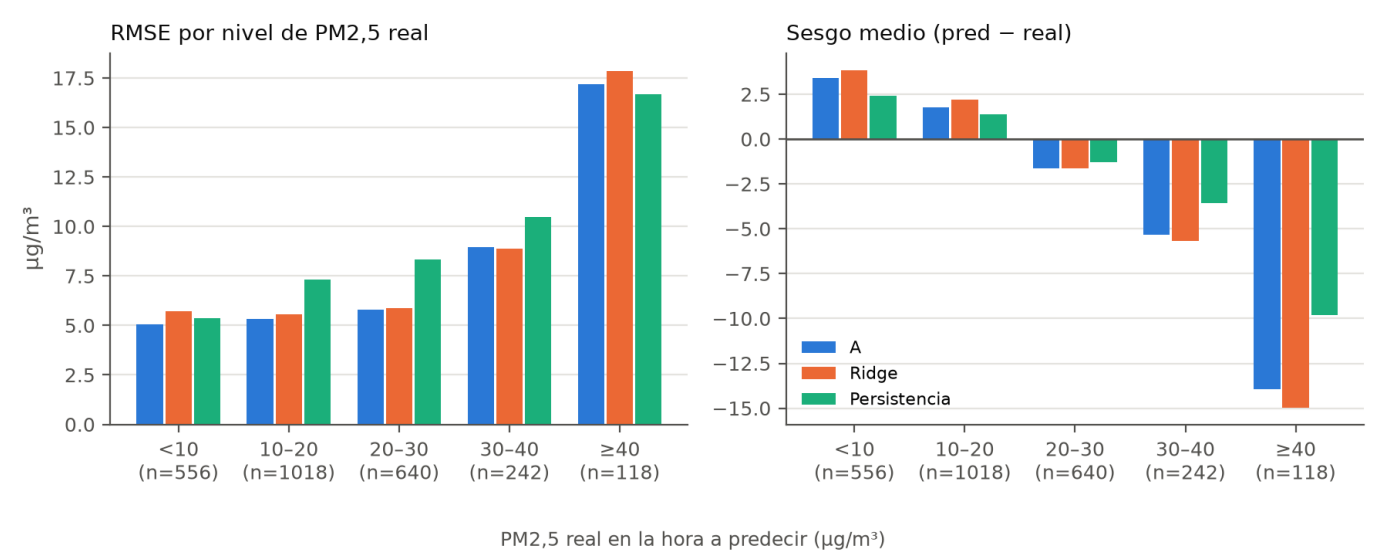
Recoge solo el **24 %** de cada subida y el **40 %** de cada bajada

Ignora un pico de hace 12 h y reproduce las series constantes

No es un atajo por artefactos del conjunto: imputación y mes no cambian el error. Es una estrategia conservadora que reacciona tarde.

ANÁLISIS DE FALLAS

Falla al inicio de los episodios, justo cuando importa



Regresión a la media: +3,4 en aire limpio, −14,0 en episodios ≥ 40

Subidas ≥ 5 µg/m³: RMSE 10,5 frente a 3,9 en horas estables

De los 20 peores errores, el 90 % son subestimaciones en subidas hacia episodios ≥ 40, sobre todo de 7 a 9 a. m. y cerca de la medianoche. Ridge presenta el mismo patrón, lo que sugiere una limitación compartida por la información de entrada.

STN · Beijing → Fontibón · 14 · Sesgo = predicción − real, en µg/m³

FALLAS · CALIBRACIÓN DE LA CONFIANZA

Los intervalos cumplen en promedio y fallan en los picos

PM2,5 real	Cobertura 80 %	Cobertura 90 %
< 10	86 %	93 %
10–20	85 %	93 %
20–30	78 %	90 %
30–40	49 %	69 %
≥ 40	22 %	33 %

Intervalos conformales con los errores de validación: en total cubren 77–78 % y 87 %, casi lo prometido.

Pero el error crece con el nivel y un intervalo de ancho fijo no lo refleja: el modelo es más “confiado” justo donde más se equivoca.

La dispersión entre semillas (0,9 µg/m³) casi no se relaciona con el error (correlación 0,20).

STN · Beijing → Fontibón · 15 · Cobertura = fracción de valores reales dentro del intervalo; media de 3 semillas

FALLAS · FUERA DEL DOMINIO DE ENTRENAMIENTO

La red se satura cerca de 70 µg/m³

24 h constantes de	Predicción	Rango semillas
20 µg/m³	20,5	20,1–20,7
60 µg/m³	56,5	54,3–58,7
100 µg/m³	69,0	65,5–71,5
200 µg/m³	71,5	63,2–87,5

Al aproximarse y superar el máximo observado en entrenamiento, la predicción empieza a saturarse y las semillas divergen.

En test el error crece con la novedad de la ventana: RMSE 5,5 en las más típicas frente a 7,7 en las más novedosas.

El test no tuvo valores tan extremos (máximo 79,8), pero un episodio así quedaría fuera de su alcance.

STN · Beijing → Fontibón · 16 · Novedad = distancia a la ventana de entrenamiento más parecida

DICTAMEN SOBRE LA PROFUNDIDAD

Justificación parcial: gana por poco y no anticipa los episodios

Comparación

−0,19 µg/m³ frente a Ridge en 3/3 semillas. En picos mejora en test, no en validación, y la persistencia es mejor.

Costo

99.425 parámetros, 2,4–3,5 h de entrenamiento y 14 s de inferencia, frente a segundos y 0,002 s de Ridge.

Auditoría

Señal razonable, pero una estrategia de persistencia suavizada que un modelo lineal ya captura.

La transferencia desde Beijing **no se justifica**: B y C fueron peores que A y que Ridge en validación y en test.

LIMITACIONES Y PROYECCIÓN

Lo que limita el resultado y lo que haría después

Limitaciones

- Una estación, dos años; test de una sola temporada
- Tres variables, sin viento; punto de rocío calculado (Magnus)
- Red reducida; D sin entrenar y B con 2 semillas
- Tres semillas: sin inferencia formal

Continuidad

- Viento, capa de mezcla y estaciones vecinas
- Pérdidas que castiguen la subestimación
- Transferir desde dominios cercanos, no desde Beijing

Hacia producción

- Versionar datos, código y pesos
- Vigilar deriva de datos y de concepto
- Alerta si la entrada sale del rango; respaldo Ridge

CONCLUSIÓN

La STN gana por poco, no anticipa los picos y no aprovechó Beijing

Con estos datos, la profundidad aporta poco frente a Ridge y la falla principal parece estar asociada a la información disponible.

Gracias · Preguntas